

Entrega final. Regresión discontinua

Carlos Bautista

2022-08-12

```
library(dagitty)
library(rethinking)
library(tidyverse)
library(rdd)
library(rdrobust)
library(rddensity)
library(stargazer)
```

a. Artículo de Referencia

Fouirnaies, Alexander, and Andrew B Hall. 2014. “The Financial Incumbency Advantage: Causes and Consequences.” *J. Polit.* 76 (3): 711–24.

b. Descripción General

Este artículo utiliza un diseño de regresión discontinua para estimar el efecto causal de la titularidad del cargo en las contribuciones de campaña en la Cámara de Representantes de los Estados Unidos y las legislaturas estatales.

En ambos entornos, la titularidad en el cargo de un candidato provoca un aumento de aproximadamente 20 a 25 puntos porcentuales en la proporción de donaciones que fluyen hacia el partido del titular.

Si bien se demuestra que el tamaño de este efecto no varía con la experiencia del legislador y no parece depender de los beneficios de los titulares de cargos, sí se encuentra que el efecto es principalmente resultado de donaciones de grupos de interés, especialmente donantes de industrias sometidas a fuertes regulaciones.

c. Análisis

Las unidades de análisis son los Distritos (legislaturas estatales y de la Cámara de Representantes de los Estados Unidos. El tratamiento es el estatus de titular en la elección (El candidato es el titular del cargo: Sí = 1, No = 0) y el resultado serán las contribuciones de campaña en la elección (recibos de donaciones de campaña en el próximo ciclo electoral).

La variable de score es el margen de ganancia de la participación del voto de- mócrata, es decir, la diferencia entre la participación demócrata del voto bipar- tidista y el 50 %, el porcentaje de voto necesario para ganar un cargo.

Se busca analizar si las contribuciones de campaña donadas al partido en el próximo ciclo electoral en los distritos que apenas ganó difieren sistemáticamente de las donaciones que el partido recibe en los distritos que apenas perdió. Esta diferencia se puede atribuir al impacto de la titularidad en el cargo del candidato.

d. Datos

El conjunto de datos es incumbency.csv. Utilice en el análisis sólo la infor- mación para las elecciones legislativas estatales, esto es, 32,670 observaciones a nivel de distrito legislativo estatal.

La variable de score es el margen de victoria demócrata en t en el distrito (el porcentaje de votos obtenido por el partido demócrata menos el porcentaje de votos obtenido por su oponente más fuerte), y el tratamiento

es ganar la elección t . El Partido Demócrata gana las elecciones cuando su margen de victoria es positivo y pierde cuando es negativo.

e. Instrucciones

1. Escriba una introducción del análisis que realizará con ayuda de este conjunto de datos de acuerdo al contexto del problema.


El presente ejercicio busca evaluar el efecto causal de la titularidad en el cargo en las donaciones a campañas de los congresos locales de EUA. Para medir el efecto se utilizará la metodología de regresión discontinua y se enfoca en las elecciones cerradas, de tal forma que esto funciona como si la titularidad del cargo hubiera sido asignada de manera aleatoria (para demócratas y republicanos).

2. Ilustre correctamente los factores considerados en dicho análisis. Para ello, realice el gráfico directo acíclico (DAG) que muestre la teoría de cambio detrás de la relación causal que busca analizar y cuantificar el artículo.

Se genera el DAG

```
dag_rdd <- dagitty('dag{
    "Score" [pos="0,1"]
    "Donaciones" [pos="1,1"]
    "corte" [pos="-1,1"]
    "Titular del cargo" [pos="0,0"]
    "Cov observables" [pos="0,2"]
    "Score" -> "Donaciones"
    "Score" -> "corte"
    "corte" -> "Titular del cargo"
    "Titular del cargo" -> "Donaciones"
    "Cov observables" -> "Score"
    "Cov observables" -> "Donaciones"}')

drawdag(dag_rdd, col_arrow="red")
```



3. Luego de leer el conjunto de datos, seleccione la submuestra de las 32,670 de elecciones locales y realice un análisis exploratorio de las variables y describa su comportamiento, especialmente la variable de score.

El resumen estadístico para las variables numéricas de interés se muestra a continuación:

```

dta <- read_csv("data/incumbency.csv")
dta <- dta %>% filter(statelevel == 1)
dta_short <- dta %>% select(statelevel, rv, dv_money, total_race_money, total_votes,
                           dem_inc, rep_inc, total_group_money, treat)

attach(dta)
attach(dta_short)

dta_short %>% select_if(is.numeric) %>% summary

```

```

##      statelevel      rv      dv_money      total_race_money
##  Min.   :1      Min.   : -50.000      Min.   : 0.00      Min.   : 1
##  1st Qu.:1      1st Qu.: -16.055      1st Qu.: 6.54      1st Qu.: 16530
##  Median :1      Median : 0.135      Median : 50.61     Median : 48386
##  Mean   :1      Mean   : 1.358      Mean   : 50.78     Mean   : 129657
##  3rd Qu.:1      3rd Qu.: 20.079      3rd Qu.: 96.80     3rd Qu.: 123543
##  Max.   :1      Max.   : 50.000      Max.   :100.00     Max.   :8819682
##
##                      NA's      :5467
##      total_votes      dem_inc      rep_inc      total_group_money
##  Min.   : 527      Min.   :0.0000      Min.   :0.0000     Min.   : 0
##  1st Qu.: 7748     1st Qu.:0.0000     1st Qu.:0.0000     1st Qu.: 8225
##  Median :14914     Median :0.0000     Median :0.0000     Median : 23500
##  Mean   :23793     Mean   :0.2744     Mean   :0.2555     Mean   : 63663
##  3rd Qu.:29369     3rd Qu.:1.0000     3rd Qu.:1.0000     3rd Qu.: 63224
##  Max.   :429470     Max.   :1.0000     Max.   :1.0000     Max.   :4604704

```

```
##
##      treat
## Min.   :0.0000
## 1st Qu.:0.0000
## Median :1.0000
## Mean   :0.5017
## 3rd Qu.:1.0000
## Max.   :1.0000
##
```

También se genera resumen descriptivo para variables categóricas de interés, y podemos observar cómo están distribuidas.

```
dta_cat <- dta %>% select(dem_inc, rep_inc, treat)
dta_cat$dem_inc <- as.factor(dta_cat$dem_inc)
dta_cat$rep_inc <- as.factor(dta_cat$rep_inc)
dta_cat$treat <- as.factor(dta_cat$treat)
table(dta_cat$dem_inc)
```

```
##
##      0      1
## 23705  8965
```

```
table(dta_cat$rep_inc)
```


```
##
##      0      1
## 24324  8346
```

```
table(dta_cat$treat)
```

```
##
##      0      1
## 16281 16389
```

4. Construya el diagrama de dispersión entre la variable de score (eje x) y la proporción de donaciones (eje y), distinguiendo cada punto por grupo de tratamiento y de control.

```
ggplot(dta, aes(x = rv, y = dv_money)) +
  geom_point(aes(color = as.factor(treat))) +
  labs(x= "score", y ="prop. donaciones")
```



5. Ahora revise el ejemplo empírico del artículo complementario (Skovron y Titiunik (2015), a partir de la página 31) que utiliza el mismo conjunto de datos del artículo de referencia y explique cuál es el punto de corte identificado para el análisis de una regresión discontinua. ¿Porqué sería útil esta estrategia empírica?

El punto de corte es cero, este valor define si una observación forma parte del grupo de tratamiento o de control.


En términos del contexto del problema, recordemos que está basado en la variable score, que mide la diferencia en la votación y es el margen de victoria o derrota de un candidato demócrata en particular. Es decir, si el valor de score es positivo implica que el candidato fue el ganador en dicho distrito, y viceversa.

De tal forma que, al enfocarnos en elecciones cerradas, si el valor de score es positivo entonces dicha observación forma parte del grupo de tratamiento, y si es negativo del de control.

6. Lleve a cabo el análisis de continuidad en el conjunto de datos. Replique en particular la Figura 11 para analizar dicha continuidad y explique sus conclusiones. En R puede utilizar la función `rddensity`.

Siguiento a Skovron y Titiunik (2015) podemos validar el diseño del modelo analizando la densidad de la variable continua (margen de victoria del candidato demócrata) alrededor del punto de corte (0). Se genera histograma para analizar de manera visual

```
ggplot(dta, aes(x = rv, fill = as.factor(treat))) +
  geom_histogram(binwidth = 0.7) +
  geom_vline(xintercept = 0) +
  xlim(-30, 30)
```



Asimismo, podemos validar realizando una prueba de falsificación, para ello se utiliza la función `rddensity` para probar la hipótesis nula de que la densidad de la variable score es continua al punto de corte. La prueba nos arroja un p-value de 0.3594, por lo que no tenemos evidencia para rechazar que haya discontinuidad en el punto de corte. Podemos proceder con nuestro análisis de regresión discontinua.

```
density <- rddensity(X = rv)
summary(density)
```

```
##
## Manipulation testing using local polynomial density estimation.
##
## Number of obs =      32670
## Model =          unrestricted
## Kernel =         triangular
## BW method =      estimated
## VCE method =     jackknife
##
## c = 0            Left of c      Right of c
## Number of obs    16281         16389
## Eff. Number of obs 2770         3176
## Order est. (p)    2             2
## Order bias (q)    3             3
## BW est. (h)       5.458         6.935
##
## Method           T              P > |T|
## Robust           -0.9164         0.3594
##
```

```
##
## P-values of binomial tests (H0: p=0.5).
##
## Window Length / 2      <c      >=c      P>|T|
## 0.031                  13       7       0.2632
## 0.062                  31      18       0.0854
## 0.092                  45      34       0.2604
## 0.123                  65      46       0.0871
## 0.154                  76      67       0.5036
## 0.185                  87      83       0.8181
## 0.215                 108     105       0.8910
## 0.246                 124     114       0.5597
## 0.277                 136     125       0.5360
## 0.308                 151     142       0.6403
```

7. Ahora, analice el efecto del tratamiento en cinco covariables predeterminadas. Confirme que no encuentran ningún efecto del tratamiento en ninguna de ellas. Para ello, replique los resultados de la tabla 1 y los gráficos de la Figura 12. En R puede utilizar las funciones `rdrobust` y `rdplot`. Explique claramente sus conclusiones.

El siguiente paso para validar nuestro análisis de RDD es analizar el efecto del tratamiento en las covariables de interés: [-] Dinero total [-] Dinero de grupos con intereses [-] Total de votos [-] Titular del cargo es demócrata [-] Titular del cargo es republicano

Esperaríamos que el tratamiento no tenga ningún efecto causal en las covariables. Para ello utilizamos la función `rdrobust`. Como se observa, los p-values robustos son altos y no significativos, por lo que no tenemos evidencia que el tratamiento tenga un efecto causal en alguna de las covariables de interés.

```
mod_1 <- rdrobust(y = total_race_money, x = rv)
mod_2 <- rdrobust(y = total_group_money, x = rv)
mod_3 <- rdrobust(y = total_votes, x = rv)
mod_4 <- rdrobust(y = dem_inc, x = rv)
mod_5 <- rdrobust(y = rep_inc, x = rv)

print(c("total_money", summary(mod_1)))
```

```
## Sharp RD estimates using local polynomial regression.
##
## Number of Obs.          32670
## BW type                 mserd
## Kernel                  Triangular
## VCE method              NN
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     5798       4919
## Order est. (p)          1           1
## Order bias (q)          2           2
## BW est. (h)             11.114     11.114
## BW bias (b)             17.304     17.304
## rho (h/b)              0.642      0.642
## Unique Obs.            11187     10946
##
## =====
##          Method      Coef. Std. Err.      z    P>|z|      [ 95% C.I. ]
```

```
## =====
##   Conventional -7945.270 23075.293   -0.344    0.731[-53172.014 , 37281.473]
##           Robust      -      -   -0.538    0.591[-68989.793 , 39290.412]
## =====
## [1] "total_money"
```

```
print(c("total_group_money", summary(mod_2)))
```

```
## Sharp RD estimates using local polynomial regression.
```

```
##
## Number of Obs.          32670
## BW type                mserd
## Kernel                  Triangular
## VCE method              NN
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     6347       5384
## Order est. (p)          1          1
## Order bias (q)          2          2
## BW est. (h)             12.192     12.192
## BW bias (b)             18.918     18.918
## rho (h/b)               0.644      0.644
## Unique Obs.             11187     10946
##
## =====
##           Method      Coef. Std. Err.      z    P>|z|      [ 95% C.I. ]
## =====
##   Conventional  2712.713  5979.521    0.454    0.650 [-9006.933 , 14432.359]
##           Robust      -      -    0.522    0.602 [-10292.945 , 17761.565]
## =====
## [1] "total_group_money"
```

```
print(c("total_votes", summary(mod_3)))
```

```
## Sharp RD estimates using local polynomial regression.
```

```
##
## Number of Obs.          32670
## BW type                mserd
## Kernel                  Triangular
## VCE method              NN
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     3077       2781
## Order est. (p)          1          1
## Order bias (q)          2          2
## BW est. (h)             6.024      6.024
## BW bias (b)             10.430     10.430
## rho (h/b)               0.578      0.578
## Unique Obs.             11187     10946
##
## =====
##           Method      Coef. Std. Err.      z    P>|z|      [ 95% C.I. ]
## =====
```



```
## Conventional -1629.146 1655.606 -0.984 0.325 [-4874.074 , 1615.781]
## Robust - - -1.125 0.261 [-5926.471 , 1605.003]
## =====
## [1] "total_votes"
```

```
print(c("dem_inc", summary(mod_4)))
```

```
## Sharp RD estimates using local polynomial regression.
##
## Number of Obs.          32670
## BW type                mserd
## Kernel                  Triangular
## VCE method              NN
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     4016      3568
## Order est. (p)          1          1
## Order bias (q)          2          2
## BW est. (h)             7.864      7.864
## BW bias (b)             14.648     14.648
## rho (h/b)              0.537      0.537
## Unique Obs.            11187     10946
##
## =====
## Method      Coef. Std. Err.      z    P>|z|    [ 95% C.I. ]
## =====
## Conventional  0.012    0.019    0.637    0.524    [-0.025 , 0.048]
## Robust        -        -    0.210    0.833    [-0.037 , 0.046]
## =====
## [1] "dem_inc"
```

```
print(c("rep_inc", summary(mod_5)))
```

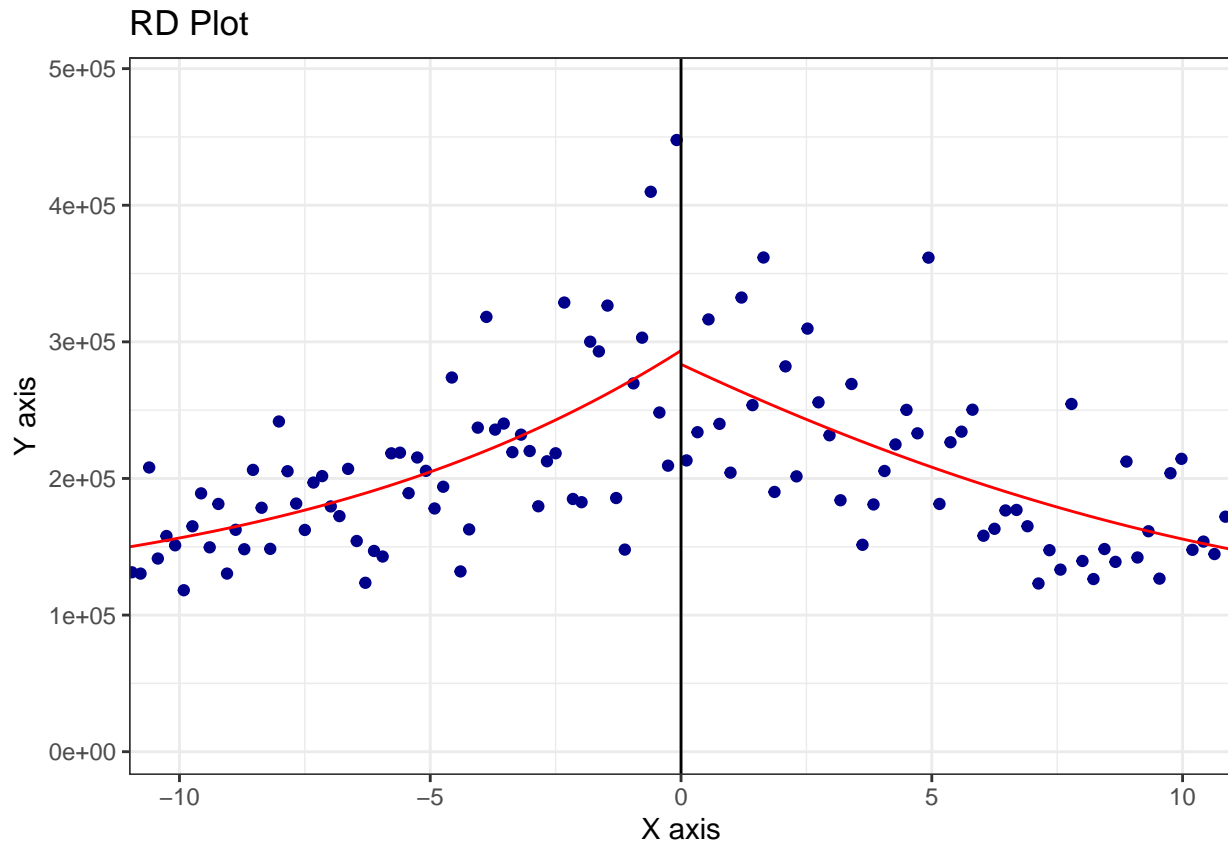
```
## Sharp RD estimates using local polynomial regression.
##
## Number of Obs.          32670
## BW type                mserd
## Kernel                  Triangular
## VCE method              NN
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     3544      3183
## Order est. (p)          1          1
## Order bias (q)          2          2
## BW est. (h)             6.952      6.952
## BW bias (b)            16.320     16.320
## rho (h/b)              0.426      0.426
## Unique Obs.            11187     10946
##
## =====
## Method      Coef. Std. Err.      z    P>|z|    [ 95% C.I. ]
## =====
## Conventional -0.019    0.019   -0.995    0.320    [-0.056 , 0.018]
```

```
##           Robust           -           -    -0.495    0.620    [-0.050 , 0.030]
## =====
## [1] "rep_inc"
```

Además, podemos validar esto de manera visual al graficar los resultados previos con `rdplot`. En las gráficas se observa que ninguna de las covariables cambia de manera significativa alrededor del punto de corte = 0.


```
g1 <- rdplot(y = total_race_money, x = rv,
             x.lim = c(-10,10))
```

```
## [1] "Mass points detected in the running variable."
```




```
g2 <- rdplot(y = total_group_money, x = rv,
             x.lim = c(-10,10),
             y.lim = c(0,200000))
```

```
## [1] "Mass points detected in the running variable."
```



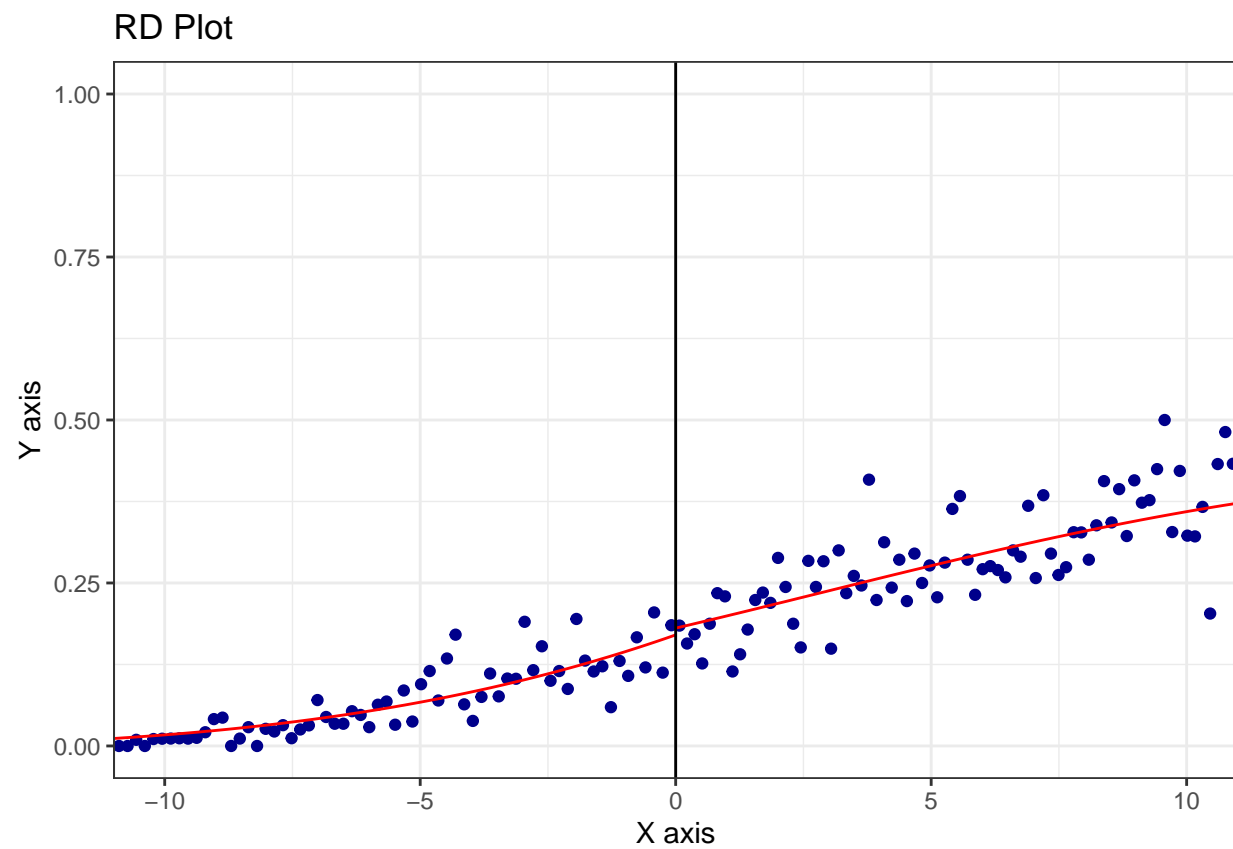
```
g3 <- rdplot(y = total_votes, x = rv,  
             x.lim = c(-10,10),  
             y.lim = c(0,50000))
```

```
## [1] "Mass points detected in the running variable."
```



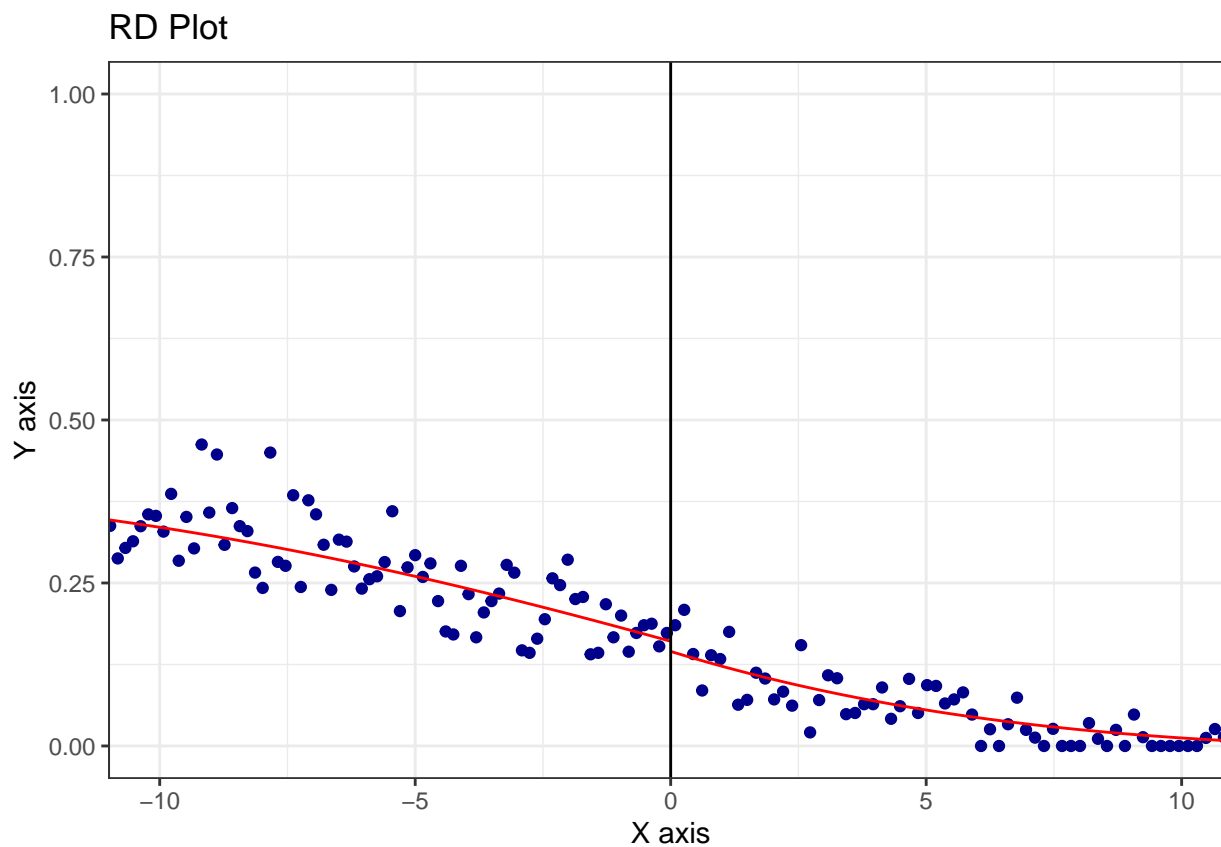
```
g4 <- rdplot(y = dem_inc, x = rv,  
             x.lim = c(-10,10),  
             y.lim = c(0, 1))
```

```
## [1] "Mass points detected in the running variable."
```



```
g5 <- rdplot(y = rep_inc, x = rv,  
             x.lim = c(-10,10),  
             y.lim = c(0,1))
```

```
## [1] "Mass points detected in the running variable."
```



g1

```
## Call: rdplot
##
## Number of Obs.          32670
## Kernel                  Uniform
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     16281      16389
## Order poly. fit (p)      4          4
## BW poly. fit (h)         50.000     50.000
## Number of bins scale     1.000      1.000
```

g2

```
## Call: rdplot
##
## Number of Obs.          32670
## Kernel                  Uniform
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     16281      16389
## Order poly. fit (p)      4          4
## BW poly. fit (h)         50.000     50.000
## Number of bins scale     1.000      1.000
```

g3

```
## Call: rdplot
##
## Number of Obs.          32670
## Kernel                  Uniform
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     16281      16389
## Order poly. fit (p)      4          4
## BW poly. fit (h)         50.000     50.000
## Number of bins scale     1.000     1.000
```

g4

```
## Call: rdplot
##
## Number of Obs.          32670
## Kernel                  Uniform
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     16281      16389
## Order poly. fit (p)      4          4
## BW poly. fit (h)         50.000     50.000
## Number of bins scale     1.000     1.000
```

g5

```
## Call: rdplot
##
## Number of Obs.          32670
## Kernel                  Uniform
##
## Number of Obs.          16281      16389
## Eff. Number of Obs.     16281      16389
## Order poly. fit (p)      4          4
## BW poly. fit (h)         50.000     50.000
## Number of bins scale     1.000     1.000
```

8. Utilice las mismas funciones para identificar el efecto causal significativo sobre la variable de resultado. Ahora debe replicar los resultados de la tablas 2 y los gráficos de la figura 13. Vea en el artículo las opciones sugeridas para ajustar el kernel de manera óptima y el grado polinomial de ajuste, así como los errores estándar robustos. Explique sus resultados.

Ahora procedemos a evaluar el efecto causal del tratamiento sobre la variable de respuesta (donaciones a campañas). Con base en lo realizado por los autores, ajustamos el modelo con polinomios de grado 1 y de grado 2.

Los resultados muestran que el tratamiento sí tiene un efecto causal en la variable de respuesta: en distritos con elecciones cerradas donde ganaron los demócratas, las donaciones en las próximas elecciones aumentan en un 20% en promedio vs los distritos con elecciones cerradas donde perdieron. Este resultado también es significativo para el modelo con polinomio de grado 2 (efecto de 19.9%).

```
# modelos de tabla 2
m_p1 <- rdrobust(y = dv_money, x = rv) #grado del polinomio por default es 1
m_p2 <- rdrobust(y = dv_money, x = rv, p=2)
```

```
print(c("grado polinomio = 1",summary(m_p1)))
```

```
## Sharp RD estimates using local polynomial regression.
```

```
##
## Number of Obs.          27203
## BW type                 mserd
## Kernel                  Triangular
## VCE method              NN
##
## Number of Obs.          13292      13911
## Eff. Number of Obs.     3994       3435
## Order est. (p)           1          1
## Order bias (q)           2          2
## BW est. (h)              9.270      9.270
## BW bias (b)              19.028     19.028
## rho (h/b)                0.487      0.487
## Unique Obs.              9006      9199
##
## =====
##      Method      Coef. Std. Err.      z    P>|z|      [ 95% C.I. ]
## =====
##   Conventional   20.532    1.285    15.984    0.000   [18.014 , 23.049]
##      Robust       -        -    14.037    0.000   [17.183 , 22.760]
## =====
## [1] "grado polinomio = 1"
```

```
print(c("grado polinomio = 2",summary(m_p2)))
```

```
## Sharp RD estimates using local polynomial regression.
```

```
##
## Number of Obs.          27203
## BW type                 mserd
## Kernel                  Triangular
## VCE method              NN
##
## Number of Obs.          13292      13911
## Eff. Number of Obs.     6852       5928
## Order est. (p)           2          2
## Order bias (q)           3          3
## BW est. (h)              16.602     16.602
## BW bias (b)              22.771     22.771
## rho (h/b)                0.729      0.729
## Unique Obs.              9006      9199
##
## =====
##      Method      Coef. Std. Err.      z    P>|z|      [ 95% C.I. ]
## =====
```




```
## Conventional 19.928 1.412 14.117 0.000 [17.161 , 22.695]
## Robust - - 12.369 0.000 [16.732 , 23.033]
## =====
## [1] "grado polinomio = 2"
```

Se grafican los efectos (figura 13) para confirmar de manera visual. En la primera gráfica se utilizan valores donde el margen de diferencia fue de ± 10 puntos y en la segunda gráfica se utilizan todas las elecciones. El efecto causal es evidente de manera visual en ambos casos.


```
#gráfica con todos los datos
g_p1_all <- rdplot(y = dv_money, x = rv)
```

```
## [1] "Mass points detected in the running variable."
```



```
#gráfica con diferencia de +-10
g_p1 <- rdplot(y = dv_money, x = rv,
               x.lim = c(-10,10))
```

```
## [1] "Mass points detected in the running variable."
```



```
g_p1_all
```

```
## Call: rdplot
##
## Number of Obs.          27203
## Kernel                  Uniform
##
## Number of Obs.          13292      13911
## Eff. Number of Obs.     13292      13911
## Order poly. fit (p)      4          4
## BW poly. fit (h)         50.000     50.000
## Number of bins scale     1.000      1.000
```

```
g_p1
```

```
## Call: rdplot
##
## Number of Obs.          27203
## Kernel                  Uniform
##
## Number of Obs.          13292      13911
## Eff. Number of Obs.     13292      13911
## Order poly. fit (p)      4          4
## BW poly. fit (h)         50.000     50.000
## Number of bins scale     1.000      1.000
```

9. Ahora pruebe si puede encontrar algún efecto del tratamiento para los límites de otros cortes diferentes del original ($c = 0$). Evalúe un par diferente a ellos y discuta. Compare con los resultados de la tabla 3.

Siguiendo a Skovron y Titunik (2015) probamos para puntos de corte de 1 y -3. Las pruebas arrojan estimadores cercanos a cero (no hay diferencia en esos puntos de corte) los p-values no son significativos, por lo que no hay evidencia de que haya discontinuidad en los puntos de corte placebo.

```
m_c1 <- rdrobust(y = dv_money, x = rv, c = 1) #grado del polinomio por default es 1
m_c3 <- rdrobust(y = dv_money, x = rv, c = -3)

print(c("corte placebo = 2",summary(m_c1)))
```

```
## Sharp RD estimates using local polynomial regression.
```

```
##
```

```
## Number of Obs.                27203
```

```
## BW type                        mserd
```

```
## Kernel                        Triangular
```

```
## VCE method                     NN
```

```
##
```

```
## Number of Obs.                13692      13511
```

```
## Eff. Number of Obs.          1271       1204
```

```
## Order est. (p)                1          1
```

```
## Order bias (q)                2          2
```

```
## BW est. (h)                   3.125      3.125
```

```
## BW bias (b)                   8.042      8.042
```

```
## rho (h/b)                     0.389      0.389
```

```
## Unique Obs.                   9406      8799
```

```
##
```

```
## =====
```

```
##      Method      Coef. Std. Err.      z    P>|z|      [ 95% C.I. ]
```

```
## =====
```

```
## Conventional   -1.994    2.257   -0.883   0.377   [-6.418 , 2.430]
```

```
## Robust         -         -   -1.283   0.200   [-7.764 , 1.621]
```

```
## =====
```

```
## [1] "corte placebo = 2"
```

```
print(c("corte placebo = -3",summary(m_c3)))
```

```
## Sharp RD estimates using local polynomial regression.
```

```
##
```

```
## Number of Obs.                27203
```

```
## BW type                        mserd
```

```
## Kernel                        Triangular
```

```
## VCE method                     NN
```

```
##
```

```
## Number of Obs.                12055      15148
```

```
## Eff. Number of Obs.          2005       1906
```

```
## Order est. (p)                1          1
```

```
## Order bias (q)                2          2
```

```
## BW est. (h)                   4.668      4.668
```

```
## BW bias (b)                   9.363      9.363
```

```
## rho (h/b)                     0.499      0.499
```

```
## Unique Obs.          7769          10436
##
## =====
##      Method      Coef. Std. Err.      z    P>|z|      [ 95% C.I. ]
## =====
##   Conventional   -2.139      1.801    -1.188    0.235    [-5.670 , 1.391]
##      Robust        -         -     -1.467    0.142    [-6.844 , 0.984]
## =====
## [1] "corte placebo = -3"
```

10. Escriba la conclusión general del análisis realizado. Interprete la cuantificación del efecto causal y discuta la utilidad y ventajas de aplicar la estrategia empírica seleccionada para la cuantificación del efecto causal.

El análisis de regresión discontinua muestra que, para el partido demócrata, contar con la titularidad del cargo de elección popular en los congresos locales de EUA tiene en promedio un efecto positivo de 20% en las donaciones recibidas en la próxima elección, en comparación con los distritos donde no se ganó la elección (el titular no es demócrata).

Esto se probó a través de un análisis de regresión discontinua, ya que fue posible identificar un punto de corte en la variable dependiente que permitió diseñar los grupos de tratamiento y control de manera robusta.

Esto se validó a través de diferentes pruebas que mostraron que la discontinuidad no existía en el resto de covariables, sólo en la variable que genera el tratamiento. Además se validaron los resultados generando pruebas con puntos de corte placebo que efectivamente mostraron que el punto de corte es importante y significativo. Podemos entonces concluir que el efecto causal identificado existe y es significativo, y que el método utilizado es robusto.